

## 4. sklop: Algoritem Metropolis-Hastings

### 1 Primer: normalni model z znano varianco

Uporabili bomo algoritem Metropolis-Hastings za primer iz 3. sklopa, kjer so bili naši podatki število ur, ki so jih dijaki potrebovali za pripravo domače naloge.:

```
x <- c(2.11, 9.75, 13.88, 11.3, 8.93, 15.66, 16.38, 4.54, 8.86, 11.94,  
12.47, 11.11, 11.65, 14.53, 9.61, 7.38, 3.34, 9.06, 9.45, 5.98,  
7.44, 8.5, 1.55, 11.45, 9.73)
```

Privzemimo normalni model z znano varianco  $\sigma^2 = 4$ , torej  $(X_i|\theta) \sim N(\theta, \sigma^2 = 4)$ , medtem ko naj bo apriorna porazdelitev  $\theta \sim N(\theta_0 = 6, \tau_0^2 = 9)$ . Zanimala nas je aposteriorna porazdelitev  $(\theta|X)$ , ki vemo, da je porazdeljena normalno  $N(\mu_1, \tau_1^2)$ , kjer sta parametra enaka:

$$\mu_1 = \frac{\tau_0^2}{\frac{\sigma^2}{n} + \tau_0^2} \bar{X} + \frac{\frac{\sigma^2}{n}}{\frac{\sigma^2}{n} + \tau_0^2} \mu_0$$
$$\tau_1^2 = \frac{\frac{\sigma^2}{n} \cdot \tau_0^2}{\frac{\sigma^2}{n} + \tau_0^2}$$

Pravo aposteriorno porazdelitev torej poznamo.

V nalogi jo bomo aproksimirali s pomočjo algoritma Metropolis-Hastings.

## 2 Naloge za vaje, ki so hkrati domača naloga

Za primer iz 3. sklopa aproksimirajte aposteriorno porazdelitev s pomočjo algoritma Metropolis-Hastings, kjer sledite spodnjim korakom.

1. Sami v R-u sprogramirajte algoritem Metropolis-Hastings za naš primer. Izberite smiselno *predlagalno jedro*  $q(\cdot|\theta^{(n-1)})$  (npr:  $q(\cdot|\theta^{(n-1)}) \sim N(\theta^{(n-1)}, \sigma_q^2 = 0.1^2)$ ); lahko tudi izberete drugo porazdelitev). Ključno je, da algoritem sprogramirate sami, pri čemer splošnost kode in učinkovitost implementacije nista pomembni. Opomba:  $f(X|\theta)$  je verjetje za  $X = (X_1, \dots, X_n)$ , kjer so  $X_i$  normalno porazdeljeni:  $f(X|\theta) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \cdot \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \theta)^2\right)$ .
2. Preizkusite algoritem na našem primeru, kjer si sami izberite neko smiselno začetno vrednost  $\theta^{(0)}$  in varianco *predlagalne gostote* (v zgornjem primeru smo jo označili  $\sigma_q^2$ ). Opomba: zaradi numerične stabilnosti ob vsaki iteraciji izračunajte logaritem verjetnosti  $\rho(\theta^{(n-1)}, y)$  in na podlagi tega logaritma se odločite, kakšen bo  $\theta^{(n)}$ . Rezultate predstavite na naslednji način:
  - Narišite celotno dobljeno zaporedje  $\{\theta^{(0)}, \theta^{(1)}, \dots, \theta^{(S)}\}$  (naj bo  $S$  vsaj 30000 - lahko tudi vzamete več iteracij). Lahko uporabite funkcijo `plot(..., type='l')`.
  - Narišite le prvih 500 ali pa 5000 členov.
  - Narišite celotno zaporedje, kjer uporabite ustrezen *burn-in* parameter  $B$ .
  - Za tako izbrano zaporedje grafično predstavite aposteriorno porazdelitev in jo grafično primerjajte s pravo (teoretično) aposteriorno porazdelitvijo.
  - Ocenite parameter in 95% interval zaupanja za parameter iz izbranega zaporedja ter primerjajte z ocenami iz prave aposteriorne porazdelitve.
3. Poženite vas algoritem pri neki nesmiselni začetni vrednosti. Rezultate predstavite:
  - Narišite celotno dobljeno zaporedje  $\{\theta^{(0)}, \theta^{(1)}, \dots, \theta^{(S)}\}$ .
  - Narišite le prvih 500 ali pa 5000 členov.
  - Določite vrednost  $B$ , ki bi bila smiselna za vaš primer. Narišite celotno zaporedje, kjer uporabite ustrezen  $B$ .
4. Pri neki smiselni začetni vrednosti poženite algoritem pri nekaj različnih variancah za *predlagalno jedro*. Pri izboru pretiravajte v obe smeri (spomnite se, kakšni so po velikosti naši podatki), tako da boste grafično opazili razlike na prvih npr. 500 iteracijah. Rezultate predstavite:
  - Za vsak primer narisite prvih nekaj (nekje med 500 in 5000) členov in še celotno zaporedje.
  - Komentirajte razlike in zakaj do njih pride. Kaj in zakaj vas moti pri izbranih primerih?
  - Kakšen bi bil v splošnem (ne vezano na naš vzorec) vaš predlog glede izbora variance *predlagalnega jedra* oz. kakšen bi bil predlog za izbor končnega zaporedja?