

2. sklop: Poissonov model

1 Podatki

Imamo zgodovinske podatke o številu rojstev četverckov na leto v Prusiji za obdobje 69 let (Ladislaus von Bortkiewicz), za katere je znano, da se dobro prilegajo Poissonovi porazdelitvi.

```
(podatki <- data.frame(stevilo.cetverckov = 0:6,  
                      stevilo.let = c(14,24,17,9,2,2,1)))
```

```
##   stevilo.cetverckov stevilo.let  
## 1                   0          14  
## 2                   1          24  
## 3                   2          17  
## 4                   3           9  
## 5                   4           2  
## 6                   5           2  
## 7                   6           1
```

2 Verjetnostni model za nas primer

Vzorec X_1, X_2, \dots, X_n , kjer je:

- $n = 69$ stevilo let,
- X_i predstavlja število rojstev četverckov v i -tem letu,
- $X_i \mid \lambda \sim \text{Pois}(\lambda)$,
- $P(X_i = k \mid \lambda) = \frac{1}{k!} \lambda^k e^{-\lambda}$ za $k \in \{0, 1, 2, \dots\}$,
- $E(X_i) = \lambda$ (**parameter, ki nas zanima**),
- $\text{Var}(X_i) = \lambda$.

Za vsako leto imamo sledeče število rojenih četverckov:

```
(x <- rep(podatki$stevilo.cetverckov, podatki$stevilo.let))
```

```
## [1] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1  
## [39] 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 3 3 3 3 3 3 3 3 3 3 4 4 5 5 6
```

Vse in še več o Poissonovi porazdelitvi najdete tu (pripravil doc. dr. Gaj Vidmar):

- članek: [http://ims.mf.uni-lj.si/archive/17\(2\)/31.pdf](http://ims.mf.uni-lj.si/archive/17(2)/31.pdf)

3 Naloge

3.1 Kako bi ocenili parameter λ s “klasicno” frekventisticno statistiko? Katere metode bi lahko uporabili?

3.2 Ocenjevanje v Bayesovi statistiki

Bayesova formula:

$$f(\vartheta|\vec{x}) = \frac{f(\vec{x}|\vartheta)f(\vartheta)}{f(\vec{x})} \propto f(\vec{x}|\vartheta)f(\vartheta).$$

Opazeni podatki:

- n : stevilo let
- $k = \sum_{i=1}^n X_i$: stevilo cetverckov

```
(n <- length(x))
```

```
## [1] 69
```

```
(k <- sum(x))
```

```
## [1] 109
```

3.2.1 Izracunajte parametre apriorne porazdelitve

Za apriorno porazdelitev izberite Gama porazdelitev, ki je v primeru Poissonove porazdelitve podatkov konjugirana porazdelitev (ang. *conjugate prior*; pomeni, da apriorna in aposteriorna porazdelitev pripadata enaki družini porazdelitev), zato se lahko uporablja tudi izraz **Gama-Poissonov model**.

Gostota Gama porazdelitve pri parametrih $\alpha, \beta > 0$:

$$f(\lambda | \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \lambda^{\alpha-1} e^{-\beta\lambda},$$

- $E(\text{Gama}(\alpha, \beta)) = \frac{\alpha}{\beta}$,
- $\text{Var}(\text{Gama}(\alpha, \beta)) = \frac{\alpha}{\beta^2}$.

Izracunajte α in β apriorne porazdelitve, pri cemer upostevajte, da je povprecje apriorne porazdelitve enako 1.5 (torej tolikšno je povprečno število rojenih četverckov na leto), medtem ko standardni odklon znasa 0.5.

```
E <- 1.5
```

```
SD <- 0.5
```


```
beta <- E/SD/SD
```

```
alpha <- E * beta
```

3.2.2 Narisite gostoto apriorne porazdelitve (funkcija dgamma)

```
lambda <- seq(0, 4, length=500)
apriorna_porazdelitev <- dgamma(lambda, alpha, beta)


plot(lambda, apriorna_porazdelitev, type='l', col='red', ylab='',
      xlab=expression(lambda))
```



3.2.3 Vemo, da je aposteriorna porazdelitev porazdeljena Gama. Izracunajte parametre aposteriorne porazdelitve in narisite njeno gostoto (na istem grafu kot za apriorno porazdelitev)

```
alpha_apost <- alpha + k
beta_apost <- beta + n
aposteriorna_porazdelitev <- dgamma(lambda, alpha_apost, beta_apost)

plot(lambda, apriorna_porazdelitev, type='l', col='red', ylab='',
      xlab=expression(lambda),
      ylim=c(0, max(c(max(apriorna_porazdelitev),
                       max(aposteriorna_porazdelitev)))))
lines(lambda, aposteriorna_porazdelitev, col='blue')
legend("topright", legend = c("apriorna", "aposteriorna"),
      col = c("red", "blue"), lty = 1, bty = "n", cex = 1.3)
```



3.2.4 Izračunajte $P(1.1 \leq \lambda \leq 1.9)$ in $P(1.1 \leq \lambda \leq 1.9|\vec{x})$

```
sum(pgamma(c(1.1, 1.9), alpha, beta) * c(-1, 1))
```

```
## [1] 0.5811641
```


```
sum(pgamma(c(1.1, 1.9), alpha_apost, beta_apost) * c(-1, 1))
```

```
## [1] 0.9839279
```

3.2.5 Izračunajte 95% centralni kredibilnostni interval za λ . Pomagajte si s funkcijo `qgamma`. Narisite meje kredibilnostnega intervala na grafu iz točke 3.2.3 (`abline(v=)`).

```
I <- qgamma(c(0.025,0.975), alpha_apost, beta_apost)

plot(lambda, apriorna_porazdelitev, type='l', col='red', ylab='',
      xlab=expression(lambda),
      ylim=c(0, max(c(max(apriorna_porazdelitev),
                      max(aposteriorna_porazdelitev)))))
lines(lambda, aposteriorna_porazdelitev, col='blue')
legend("topright", legend = c("apriorna","aposteriorna"),
      col = c("red","blue"), lty = 1, bty = "n", cex = 1.3)
abline(v=I, lty='dashed')
```



3.2.6 Srediscna cena parametra λ

Na predavanjih ste zapisali, da je pričakovana vrednost aposteriorne porazdelitve (ki je hkrati ocena za λ , označimo jo z $\hat{\lambda}$) enaka

$$\hat{\lambda} = \frac{\beta}{\beta + n} \cdot \frac{\alpha}{\beta} + \frac{n}{\beta + n} \cdot \frac{k}{n}.$$

Primerjajte $\hat{\lambda}$, apriorno oceno za λ (to je $\frac{\alpha}{\beta}$) in frekventistično oceno $\frac{k}{n}$ na danem vzorcu.

Kateri vrednosti je ocena $\hat{\lambda}$ blizje? Zakaj?

```
lambda_apriorna <- alpha/beta
lambda_aposteriorna <- beta/(beta+n)*alpha/beta + n/(beta+n)*k/n
lambda_frekvntisticna <- k/n
```

3.2.7 Kolikšna je verjetnost, da se v povprecju na leto rodijo eni do dvoji cetvorcki?

3.2.8 DODATNA NALOGA: Napovedovanje

Zanima nas, kaj lahko povemo o številu cetvorckov v prihajajočem letu ob upoštevanju podatkov zadnjih 69 let, tj. zanima nas **aposteriorna napovedna porazdelitev**.

(Ce bi nas zanimalo število cetvočkov v prihajajočem letu brez upoštevanja podatkov 69 let, potem bi nas zanimala **apriorna napovedna porazdelitev**).

V Poissonovem modelu z apriorno Gama porazdelitvijo lahko hitro izpeljemo apriorno/aposteriorno napovedno porazdelitev:

$$P(Y = K) = \frac{\Gamma(K + \tilde{\alpha})}{\Gamma(\tilde{\alpha}) K!} \tilde{\beta}^{\tilde{\alpha}} / (\tilde{\beta} + 1)^{K + \tilde{\alpha}} \quad \text{za } K \in \{0, 1, 2, \dots\}.$$

To je ravno negativna binomska porazdelitev s parametroma $r = \tilde{\alpha}$ in $p = 1/(1 + \tilde{\beta})$, zasledimo pa lahko tudi poimenovanje **Gama-Poissonova porazdelitev**.

Za $\tilde{\alpha}, \tilde{\beta}$ vstavimo primerna parametra Gama apriorne oz. aposteriorne porazdelitve.

- Izracunajte apriorno in aposteriorno napovedno porazdelitev.
- Poglejte, kaksna je razlika med pravilno izracunano aposteriorno napovedno porazdelitvijo in tisto, ki jo dobimo, ce v Poissonovo porazdelitev vstavimo naso oceno parametra $\hat{\lambda} = \alpha_{\text{apost}}/\beta_{\text{apost}}$.